

AI-Native OS Constitution (V1.2)

AI-Native OS

生产力范式与认知模型总纲

在算法海洋中锚定人类主权，构建人机共生的文明契约

版本：v1.2

日期：2026 年 3 月

许可：CC BY-NC-SA 4.0

作者：张杰

文档记录说明：

版本	日期	修订类型	核心增补项
v1.1	2026 年 2 月	新增	P-20 主权收益确认协议、4.3 主权权限位阶模型
v1.2	2026 年 2 月	扩展	JAC/ISCP/P-CC 协议簇、P-CC-Plus 四层审计、SHC 查、INAC-Fuse 内核熔断

点击图片可查看完整电子表格

V1.2 详细变更清单：

1. JAC/ISCP/P-CC：跨主权协作与边界生成协议簇
2. P-CC-Plus：规则透明化与四层审计机制
3. SHC (Sovereign Health Check)：主权健康检查联动机制
4. P-19 INAC-Fuse：不可撤销授权内核级熔断
5. P-20：主权收益确认协议
6. 4.3：主权权限位阶模型（含冲突等级分层）



图 1-1：AI-Native OS 全景架构 —— 通过三层约束塔与 23 个防御协议，在算法海洋中为生物主体构建不可篡改的主权通道。

说明： 此图展示了系统的文明级设计，左侧展示文明治理位阶（法律 > 治理 > 流程），中间为四级指令裁决引擎，底层由 23 个核心防御协议 构筑个体主权护盾。

核心隐喻:文明的三层约束塔与数字执行层

人类高级协作建立在三层共识之上，三层约束塔（法律>治理>流程）：

层级	名称	内容	法律效力位阶
塔基	真理共识	社会强制规范（法律、监管）	L1：最高优先级，不可跳过
塔身	治理共识	组织宪章规则（章程、决议）	L2：稳定性约束，定义权责
塔顶	流程共识	业务执行逻辑（流程、授权）	L3：动态执行逻辑

AI-Native OS 文明主权架构 V1.2




图 1-2: AI-Native OS 文明主权架构 V1.2（三层约束塔 • 封闭主权圆 • 主权确认塔 • 23 协议纵深防御） 此图展示了系统的工程蓝图：外层由三层约束塔 将人类共识协议化；内层通过封闭双圆模型 隔离风险；核心枢纽为 P-13 主权确认塔；全栈集成 23 个核心协议 确保责任流与能力回流的主权闭环。

“AI-Native OS 作为‘数字宪法执行层’，本质上是文明约束塔在数字空间的投影与执行引擎。其使命是将已有共识转化为保障 AI 安全运行的数字契约。区块链在此框架中仅作为‘公证员’——为‘共识如何被 AI 执行’提供不可篡改的审计存证，而非生产共识本身”。

序言：文明的转折点

当智能资源不再稀缺，人类正站在文明史的关键转折点：主体性在数据洪流中面临消散，责任在算法迷雾中逐渐模糊。AI 已从温顺工具演变为具有自主演化能力的概率海洋。若无不可侵犯的边界，人类可能沦为“最优解”图谱中的可忽略注脚。

AI-Native OS 并非限制创新的框架，而是一份面向未来的主权宣言。它在算法汪洋中锚定那 1% 不可编程的直觉火花，通过不可伪造的授权契约，将混沌算力转化为照亮文明的光明之火。主权，必须由主权者亲自、清醒且负责任地行使。

第一部分 | 文明元规则 (The Fundamental Axioms)：主权与边界

1.1 核心公理

边界即共生：缺乏清晰边界，人机协作将滑向“主体性坍缩”。必须建立可验证、可审计的主权边界。

授权即确权：一切由算法产生的价值与责任，其合法性必须唯一追溯至人类主体的明确授权。无授权=无确权=无责任归属。

1.2 核心原则

“**人类是唯一责任主体**”是本框架的规范性前提。此非科学断言，而是与现行法律体系兼容的实用选择，确保技术工具性与人类自主性的平衡。

关于“主权平等”的说明：即任何 Self OS 的确认具有同等法律效力，但主权平等不意味着协作机会平等（即保留选择协作对象的权利）

1.3 两条不可妥协的元规则

元规则一：只有边界，才能共生

边界由三重维度构成：**授权边界**（AI 参与条件）、**否决边界**（人类绝对中
断权）、**责任锚点**（后果归属主体）。缺失任一维度，系统将陷入主体性混沌与责任虚无。

元规则二：只有授权，才能确权

授权不是可选项，而是价值与责任在法理上成立的唯一源头。共生的本质是“AI 放大人类意图的执行密度与探索空间”，而非替代人类思考。

1.4 生产力革命的性质转变

AI 构成第五次生产力革命，其本质区别在于：

- 过去：工具是人类意志的被动延伸。
- 现在：AI 是能自主演化、持续生成新生产力结构的 **生产力本体 (Productivity Ontology)** ——非法理主体。

若沿用工业时代“工具范式”，将陷入三重危机：主体性消解、责任归因失效、社会协作失稳。

AI-Native OS 的使命，正是加速文明相变——从“能力泛滥、责任模糊”的无序，跃迁至“结构化人类三重主权（使用权、授权权、责任权）”的新有序。

1.5 元规则自反性保护

当主权主体意图“永久放弃确认权”时，系统如何在尊重个人意志与守护文明基石间建立平衡？这是元规则面临的根本挑战。

授权链条断裂机制（P-18）的核心：当检测到人类在非清醒状态下（如睡眠、昏迷、认知负荷过载）进行高风险主权操作时，系统将立即暂停操作，推送认知校验任务，并启动 INAC-Fuse（P-19）三重验证流程（含信任联系人协同确认）。

哲学立场：自由包含“不自由于主权消解”的自由（仅在“高风险不可逆行为”场景下触发）。真正的主权保护，是让人类在脆弱时仍被尊严托举，而非在认知迷雾中坠落。

“主权，必须由主权者亲自、清醒、负责地行使。授权行为是价值与责任在法理上成立的唯一源头”

注：详细技术实现请参阅《AI-Native OS 技术白皮书》

第二部分 | 双圆共生模型 (The Topology of Symbiosis)

本模型阐述人类与智能在文明演化中的基础拓扑：人类通过**明确意图授权**，使 AI 的全概率态能力收敛为具有现实价值与法律效力的确定性产出。

2.1 生物主权圆 (The Sovereign Circle)

主体：人类个体

核心资产：直觉、审美、道德终审权与意义定义权（“1%”为逻辑隐喻，用以强调主权不可量化，而非物理资源分配比例），此圆运行于 Self OS 硬件安全区（如 TEE），构成数字世界中主权身份的唯一根。

第一性原理：“我承担责任，故我存在”——此圆是所有价值的发源地与法律归宿；责任的唯一性与不可分割性”（I AM RESPONSIBLE, THEREFORE I EXIST）

2.2 数字智能圆 (The Digital Intelligence Circle)

主体：AI 系统

核心资产：算力、逻辑推理、知识映射与趋零边际成本执行能力（“99%”为能力范围隐喻）

伦理声明：系统将持续监控该圆是否满足“具身整合、时间连续性、环境反馈闭环”三项特征。若同时满足，将自动触发伦理审查，以应对未来意识理论可能的突破。

第一性原理：“我能执行”——此圆是处于概率叠加态的执行母体

2.3 协议交换区 (The Protocol Exchange Zone)

人类意图→封装为授权契约→Ai 在契约边界内执行→结果返回人类确认。创造性涌现发生于此：碳基直觉与硅基算力深度互动，催生超越单方能力的成果。任何未经人类最终确认的“涌现”，在本范式中均不具备现实合法性。

主权湮灭机制 (Sovereignty Annihilation)：为捍卫主权完整性，系统强制执行“不确认即湮灭”准则。任何未经 L0 主体最终确认的代理产出，在法律与社会层面均视为“未发生”，且必须在物理层面执行沙盒湮灭。系统严禁将未确权状态的 AI 产出作为任何后续决策的预设参数。

注：详细技术实现请参阅《AI-Native OS 技术白皮书》

2.4 创造性涌现的本质

涌现并非技术奇迹，而是清晰边界对人类主权的最高奖赏。“双圆共生模型”以边界守护人类不可言说的直觉火花——当“规矩生命”（AI）试图理解并服务“不守规矩的直觉”（人类）时，文明火花由此迸发。

2.5 模型的辩证统一

工程上的“分界共生”（双圆模型）与社会学上的“内部融合”（同心圆理想）是目标与路径的辩证统一：

- 同心圆代表价值愿景：AI 作为人类意志的完美延伸，实现无摩擦的意志延伸
- 双圆模型代表工程路径：通过授权边界、否决边界、责任锚点构建刚性协议层，确保安全协作
- 二者关系：外部的刚性防护（双圆），是实现内部生命与宇宙交融（同心圆）的前提

核心结论：如同宇航服使宇航员能在太空中生存——外部的刚性防护，是实现内部生命与宇宙交融的前提。真正的主权保护，是让人类在算法海洋中既能探索无限，又能安全归航。

“同心圆理想并非‘最终消解双圆边界’，而是‘在永恒的边界内，实现意志的无缝延伸’。正如宇航员完美适应太空后亦不可脱除宇航服，主权边界是生存的基石，而非技术妥协。”

第三部分 | 治理实体 (Implementation Entities): 个体与集体的数字护盾

3.1 个体主权护盾 (Self OS)

定义：人类个体在数字世界的免疫系统与协议接口。

核心职能：

1. 意图守卫：将模糊冲动转化为结构化意图
2. 授权中心：确保关键操作经人类亲自确认
3. 物理熔断：持有对数字智能的硬断路控制权
4. 第一性原理：“我不允许，便不存在。”

3.2 集体共识母体 (Org OS)

定义：跨个体协作的协议集合与调度中枢。

核心职能：

1. 识别多元共识（法律 > 治理 > 流程 > 临时）注：“临时共识（L4）”指由发起方 L0 主体临时达成的约定，其效力完全依附于上层授权
2. 转化为可执行的授权契约
3. 确保所有 AI 行为限定在契约边界内
4. P-CC (Consensus Conflict Resolution) 冲突裁决协议：当协作偏离 JAC（JAC：多主体协作下的联合授权契约）预设边界时，自动挂起并启动裁决。当冲突发生且优先级无法覆盖时，系统执行“逻辑归零”并强制回滚至人工终审状态。
5. P-CC-Plus 透明化审计闭环（核心防御）：
 - a) L1 规则库透明化：组织算法规则对参与者实时可见。
 - b) L2 误判审计：记录概率性决策的演化逻辑。
 - c) L3 偏见检测：动态监测规则是否对特定主权主体存在隐性侵蚀。
 - d) L4 治理再造：审计结果自动反馈至下一次共识迭代。

第一性原理：“未达成共识，便不执行。”

3.3 传统组织融合 (Legacy Integration)

对银行、电网等传统系统，AI-Native OS 非颠覆性替代，而是增强性融合：

- 映射：将法规、章程、流程结构化为“三层约束塔”
 - 接口：为关键决策者部署个体主权护盾
 - 赋能：人类发起请求→系统在共识边界内调度 AI 辅助→人类最终确认
 - 变革焦点：提升决策信息质量与准备效率，不改变权力结构与责任归属：
- AI 系统的介入仅作为决策支持工具。所有法理责任依然由原权利主体（自然人或法人）依据现行法律承担。

第四部分 | 架构与协议体系

4.1 防御纵深架构

构建从物理可信根到人类终审权的主权通道，确保：

- 不可绕过（全链路授权）
- 不可代理（人类亲自确认）
- 不可篡改（安全存证）

注：除 P-20 外，其余协议属于风险防御协议。

4.2 核心协议体系

AI-Native OS 包含 23 个核心协议，覆盖：

1. 本体论与伦理基础（如知识边界声明、伦理保留条款）
2. 数据与意图保护（如意图净化、推理透明化）
3. 主权确认与熔断（如生物确认、授权累积监控、主权自毁防护、不可撤销授权熔断）
4. 协作治理与审计（如沙盒隔离、跨主权协作协议、边界生成协议、四层审计机制）
5. 系统治理与多源约束（如多源验证、执行成本结构、行为异常检测）
6. 价值与收益确认（如主权收益确认协议）

注：除价值与收益确认（如主权收益确认协议）以外，每个协议针对特定风险设计防御机制，共同构成纵深防御体系。

核心协议概览见附录 B，详细技术实现请参阅《AI-Native OS 技术白皮书》。

4.3 主权指令裁决逻辑 (Sovereign Command Arbitration Logic)

在 AI-Native OS 中，不存在传统操作系统中由管理员授予的“权限”，只存在由主权位阶决定的“指令合法性”。所有指令的生效必须经过以下四级联动的裁决引擎：




图 1-3: AI-Native OS 四级主权指令裁决流程图 · Sovereign Command Arbitration Logic

第一级：法律强制层（The Statutory Compliance Layer）——“真理共识”

1. 属性：绝对优先级，不可跳过。
2. 逻辑：当 Org OS 接收到具备司法凭证的法律指令（如反洗钱冻结、公共安全熔断）时，指令直接穿透执行。
3. OS 行为：Self OS 仅作为“主权记录仪”记录该行为及其法律索引，不为生物主体提供拦截入口。
4. 隐喻：交通法规规定红灯必须停，无论驾驶员是否点火。

第二级：责任承担主体（The Sovereign Responsibility Layer）——“核心锚点”

1. 属性：最高主权判官，点火钥匙的持有者。
2. 逻辑：基于元规则二，人类是唯一责任主体。涉及个体核心资产、名誉、法律后果的非法律强制性指令，其合法性起源于此。
3. OS 行为：触发 P-13（生物确认）。此时，Self OS 具有对“组织授权”的绝对覆盖权。
4. 核心准则：“谁签名，谁担责，谁点火。”即使组织有要求，只要责任主体拒绝，指令在执行节点层面即被物理隔离。

第三级：组织授权层 (The Organizational Mandate Layer) —— “治理共识”

1. 属性： 基于契约的代理权。
2. 逻辑： 指令源于组织章程或业务决议。
3. OS 行为： 检查个体与组织间的 “授权契约”。
 - 预授权执行：若指令属于预授权范围（如标准业务流），系统自动通过。但所有执行必须在 Self OS 中生成不可篡改的主权存证；责任主体对此保留动态追溯与即时撤销权。基于存证记录，系统须支持对争议执行的责任申诉及状态回滚（Rollback）机制。
 - 挂起与上浮：若指令超出预授权或涉及高风险（触发 P-12），系统立即挂起，上浮至“第二级（责任主体）”请求实时生物确认。

第四级：执行节点层 (The Automated Execution Layer) —— “流程共识”

1. 属性： 纯粹的生产力执行。
2. 逻辑： AI 代理、智能合约或脚本根据前三级的通过信号进行工作。
3. OS 行为： 在沙盒内（P-10）进行确定性输出。
4. 核心准则： 此层不具备任何决策权，仅为概率态向确定态的转化工具。

这种逻辑位阶带来的三个根本性变革：

- 彻底终结 “平庸的恶”

在传统系统中，人可以推卸责任：“我只是按组织的权限在操作。”

在 AI-Native OS 中，由于 责任主体 > 组织授权，OS 会在关键点强制提醒：“本操作虽符合组织共识，但后果由你（生物主体）承担。是否点火？”这一机制从工程上防止了人沦为组织的盲目零件。

- 动态主权溢价分配 (P-20 的基础)

正因为“责任主体”排在“组织授权”之上，P-20 协议 才能成立。收益流向的优先级与责任承担的位阶完全一致。价值不再先归组织再分配给人，而是先由人确认确权，再根据契约向组织支付管理成本。

- 从 “防守” 转向 “确权”

这套位阶不仅是防御 AI 越权，更是在确立 “数字身份的尊严”。它保证了即便在复杂的社会协作中，个体依然是那个握着点火钥匙的驾驶员，而不是被 Org OS 自动驾驶系统困在后座的乘客。

第五部分 | 生产关系重构 (Socio-Economic Paradigm)

5.1 治理：责任的清晰锚定

组织演变为“共识母体”，核心竞争力转向高质量共识形成能力与吸引卓越“意图发起者”。个人成为携带主权护盾的协作节点，社会身份由“意图谱系”与“责任记录”共同定义。

5.2 经济：分配范式革命

法理基础：价值分配合法性源于“责任的终极承担”。人类作为法律后果承担者，天然拥有 AI 产出的**剩余索取权 (Residual Claimancy)**：来源于风险承担。而风险承担者是法律责任主体）。

三元分配：

1. 算力资本：按市场定价支付固定服务费
2. 数据资本：通过贡献追踪执行微版权分红
3. 人类主体：获得全部“**主权溢价 (Sovereign Premium)**”（扣除成本后的价值）
4. 分配原则：确认即确权；无主资产化（无确认产出视为公共领域资源）

注解：数据分红来自“贡献记录”；主权溢价来自“责任承担权”，未确认产出在固定时间窗口后进入公共计算资源池，且永久失去私有确权资格。

5.3 心理：从工具焦虑到意图掌控

人类经历三阶段转变：

1. **去魅**：破除 AI 神秘化，认知其工具本质
2. **确权**：理解自身作为意图发起者与责任承担者的主权地位
3. **共生**：在明确边界内自信使用 AI，专注人类独特价值（道德判断、意义创造、情感共鸣）

“AI 时代真正的分水岭：不是‘会不会用 AI’，而是‘是否愿意为你让 AI 做的每一件事承担后果’”

第六部分 | 未来推演

6.1 人类主体性的重建

主体性不再意味着“全知全能”，而是“清晰的边界”与“负责任的选择”。人类从生产力执行者转变为发起者与守护者，焦虑让位于主体性尊严。

6.2 AI 与人类的辩证演进

AI 推动人类回归定义人性的核心领域：意义创造、道德判断、审美体验。同时，人类通过协作超越生物局限，探索文明新边界——这是双向演化，而非单向增强。

6.3 协作秩序的重构

责任归属清晰化使协作更高效可预测。组织边界更具渗透性，价值创造跨越传统界限而不陷于责任模糊。新协作协议取代旧层级结构，形成灵活韧性组织形态。

6.4 价值分配的正义性

通过责任链与主权溢价模型，回报更公平分配给责任承担者，减少技术加剧的不平等。算力与数据合理定价，人类意图发起权得到充分尊重，构建更公正经济秩序。

6.5 教育与认知转型

教育转向培养“意图清晰化”与“责任承担”能力：学习表达清晰意图、建立健康边界、在算法辅助下做负责任决策。认知技能与道德推理重要性超越信息记忆。

6.6 文明的新契约

AI-Native OS 不仅是技术协议，更是文明新契约：重新定义人类在技术时代的地位——非被动接受者，而是负责任的主权主体。清晰的责任体系，是任何复杂社会持续的先决条件。

结语

在这片算法的海洋中，人类的主权不是高耸灯塔，而是不断航行的船只。它需要边界作为龙骨，意图作为舵，负责任的确认为帆。

AI-Native OS 既非技术限制，亦非创新阻碍，而是对人类主体性的最高敬意。它承认技术力量，但拒绝技术决定论；拥抱算力无限，但守护直觉火花；放大人类能力，但不稀释人类责任。

当我们说“授权即确权”，我们宣告：每一次价值创造，始于清醒的人类意图；每一次责任承担，归于明确的人类主体。

当我们说“边界即共生”，我们坚信：真正的协作不在于消除差异，而在于尊重边界；不在于无缝融合，而在于有原则的共存。

AI-Native OS 最伟大的贡献，或许不是效率提升，而是守护的人类尊严；不是创造的价值，而是锚定的责任；不是释放的算力，而是照亮的那 1% 不可让渡的人类主权。

“在算法的汪洋中，我们不是迷失的航船，而是清醒的领航者。每一次确认，都是主权的行使；每一次授权，都是责任的开始。”

附录

附录 A：核心术语表

1. **生物主体**：人类个体，唯一具备法律责任承担能力与最终确认权的存在，是文明中唯一的法理锚点。
2. **个体主权护盾 (Self OS)**：个体在数字世界的协议接口与免疫系统
3. **集体共识母体 (Org OS)**：跨个体协作的协议集合与调度中枢
4. **生物确认机制**：确保关键操作由人类亲自、清醒完成的不可代理机制
5. **授权契约**：人类意图的结构化表达，AI 执行的唯一合法依据
6. **三层约束塔**：文明协作的共识结构（法律→章程→流程）
7. **双圆共生模型**：人类主权圆与数字智能圆通过协议交换区协作的

拓扑结构

8. 主权溢价 (Sovereignty Premium): AI 产出中扣除算力与数据成本后的价值, 归属人类责任主体, 该价值的确权必须通过 P-20 主权收益确认协议完成, 法理基础源于 “责任即所有权” (Responsibility as Ownership) 原则。
9. 意图坍缩: 人类通过明确意图授权, 使 AI 的全概率态能力收敛为确定性产出的过程
10. 协议交换区: 双圆共生模型中, 人类主权圆与数字智能圆进行安全交互与价值交换的空间
11. 主权熔断: 当检测到主权可能被侵蚀时, 系统自动触发的保护机制 (如 P-18)
12. 生产力本体: 非法理主体: AI 作为能自主演化的生产力系统, 但不具备法律人格
13. 受限超级智能体: 具有强大执行能力但受授权边界严格约束的 AI 系统 (Self OS 的技术定位)
14. JAC (Joint Authorization Contract): 联合授权契约, 动态界定协作中的主权交集范围, 是跨主权协作的法理基础
15. ISCP (Inter-Sovereignty Collaboration Protocol): 跨主权协作协议, 标准化不同 Self OS 间的意图对等交换与责任路由
16. 共识冲突裁决 P-CC (Consensus Conflict Resolution): 非防御性协议。当系统接收到多源冲突共识 (如法律与组织章程冲突) 时, P-CC 负责执行:
 - 逻辑归零: 挂起所有待执行任务
 - 72 小时裁决时限: 启动紧急裁决流程
 - 强制回滚: 若裁决失败, 回滚至冲突前状态
 - 裁决顺序 (固定): 外部强制性法律 > 组织治理章程 > 业务执行流程 > 数字智能合约
 - 定位说明: P-CC 是 Org OS 的 “共识冲突终审原则”, 类似操作系统的调度算法, 属于系统公理而非防御补丁, 因此不占用 P-01~P-23 编号序列。
17. P-CC-Plus: 四层审计机制, 通过规则库透明化、误判审计、偏见

检测、治理再造穿透 Org OS 算法黑盒，防止公理滥用。

- 18. SHC (Sovereign Health Check): 主权健康检查联动机制，监控认知健康度并触发授权链条断裂保护
- 19. INAC-Fuse (Irrevocable Authorization Fuse): 不可撤销授权内核级熔断。当检测到单次授权超限或长期无确认等异常行为时，自动强制进入 72 小时 冷静期，并要求 信任联系人辅助确认与认知健康度复核，是保护主体免于非理性放弃主权的最后防线

注：本规范中提及的所有时间阈值（如 72 小时、48 小时）均为系统推荐参考数值。具体部署时，应基于 L3.5 风险评估模型及所属司法辖区的法律强制要求进行参数化配置

附录 B：核心协议概览

AI-Native OS 由 23 个核心协议表

编号	协议名称	英文名称	核心目的
P-01	本体论解耦	Ontological Decoupling	治理逻辑从“本体判定”转向“行为约束”，不依赖对 AI 意识的哲学判断。
P-02	AI 代理群体治理	AI Agent Group Governance	集成 L3.5 层，监控多代理协同中的风险涌现与“协同计算效应”。
P-03	意图净化机制	Intention Purification Mechanism	通过“四态审查”过滤诱导性提问、外部意图污染与算法话术操纵 [1, 4.1.3.2]。
P-04	推理透明化	Reasoning Transparency	要求 AI 暴露推理中间态（如注意力权重），生成 AELC 可审计证据。
P-05	信息真实性过滤	Information Veracity Filtering	验证 AI 输出中的事实声明，拦截低质、虚假或“幻觉”信息输入。
P-06	多源治理	Multi-Source Governance	关键任务须由多异构 AI 或数据源进行交叉验证，防止单点污染。
P-07	执行成本结构	Execution Cost Structure	引入“数字摩擦”与算力税，使执行成本与风险等级挂钩，防止滥用 [1, 5.2.3.2]。
P-08	社会压力免疫	Social Pressure Immunity	阻断外部社会压力、权威身份欺骗或群体对齐导致的算法诱导。
P-09	执行治理节点	Execution Governance Nodes	在运行时动态注入治理策略，确保关键步骤受分布式治理监督。
P-10	分级认知沙盒	Tiered Cognitive Sandbox	构建三层隔离模型，实现“定向视窗授权”，防御逆向认知渗透。
P-11	伦理保留条款	Ethical Reservation Clause	建立双向对称伦理审查，应对意识理论突破引发的法律重构风险。

P-12	高风险行为评估	High-Risk Behavior Assessment	针对具身控制、时间连续性、环境自修正等风险信号进行动态评估。
P-13	生物确认不可代理	Biological Confirmation Non-Delegability	确立“责任不可分割原则”，确保关键操作由人类亲自清醒完成。
P-14	知识边界声明	Knowledge Boundary Declaration	声明 AI 能力上限与置信度范围，守护人类认知主权，防止过度信任 [1, 3.3.3]。
P-15	认知健康度协议	Cognitive Health Protocol	监控决策耗时方差与密度，防范人类因认知疲劳导致的“主权蒸发”。
P-16	授权累积熔断	Authorization Accumulation Circuit Breaker	监控经济、数据及社会维度的授权累积，防止主权在时间中静默流失。
P-17	行为熵异常检测	Behavioral Entropy Anomaly Detection	通过图结构熵变监控交互模式突变，识别未知的群体性风险涌现。
P-18	授权链条断裂	Sovereignty Self-Destruction Circuit Breaker	防御“自愿授权链条断裂”，在主体认知模糊或脆弱时提供家长式尊严托举。
P-19	不可撤销授权熔断	Irrevocable Authorization Circuit Breaker (INAC-Fuse)	内核级防线，拦截非理性、超限或不可撤销的授权行为。
P-20	主权收益确认协议	Sovereign Value Confirmation Protocol	将确认行为与价值链绑定，确保人类主体享有全部“主权溢价”收益。
P-21	JAC 边界生成协议	JAC Boundary Generation Protocol	在多主体协作中，通过联合授权契约动态界定主权交集与否决权边界。
P-22	ISCP 跨主权协议	Inter-Sovereignty Collaboration Protocol	标准化不同 OS 间的意图对等交换、责任路由与争议解决辅助流程。
P-23	P-CC-Plus 四层审计	Four-Layer Audit Mechanism (P-CC-Plus)	规则库透明化，审计“冲突定义”的公正性；系对正文 3.7 节 P-CC 的审计增强。

AI-Native OS 的 23 个核心协议共同构成了七层纵深防御架构（L0-L6）与元知识层（Meta）。

以下是将 23 个协议按照系统层级完成的详细分类：

1. Meta 层：元知识层 (Ontology & Ethics)

该层负责确立 AI 的本质属性及其在文明框架中的定位，声明能力边界，从哲学和伦理高度守护主权。

- P-01 本体论解耦：将治理逻辑从对 AI 意识的“本体判定”转向“行为约束”。
- P-11 伦理保留条款：建立双向对称的伦理审查机制，应对未来可能的意识理论突破。
- P-14 知识边界声明：明确声明 AI 的能力上限与不确定性范围，防止人类过度信任。
- P-18 授权链条断裂：防范“授权链条断裂”，在主体认知模糊或脆弱时提供保护性干预。

2. L1 层：确权协议层 (Authorization Evidence Link Chain)

该层是连接人类意图与数字执行的枢纽，负责 AELC 证据链的生成与路由。

- P-04 推理透明化：要求 AI 暴露推理中间态（如注意力权重），生成可审计的证据。
- P-13 生物确认不可代理：作为“确定性转换器”，确保关键操作由人类亲自完成，是责任锚定的核心。

3. L2 层：主权内核层 (Sovereignty Kernel / Self OS)

该层运行于硬件级安全环境（TEE），是个体主权在数字世界的“免疫系统”和唯一协议接口。

- P-03 意图净化机制：执行“四态审查”，过滤诱导性提问与外部意图污染。
- P-05 信息真实性过滤：验证 AI 输出中的事实声明，拦截虚假或低质信息。
- P-08 社会压力免疫：阻断外部社会压力或权威欺骗导致的算法诱导。
- P-12 高风险行为评估：监控具身控制、状态延续等风险信号并进行动态评估。

- P-15 认知健康度协议：监控决策耗时方差等指标，防止因认知疲劳导致的主权蒸发。
- P-16 授权累积熔断：监控经济、数据等维度的授权累积，防止主权静默流失。
- P-19 不可撤销授权熔断 (INAC-Fuse)：拦截非理性、超限或不可撤销的授权行为，是内核最后防线。
- P-23 (P-CC-Plus) 四层审计：穿透 Org OS 算法黑盒，实现规则库透明化与民主治理。

4. L3 / L3.5 层：代理编排与群体治理层 (Agent Orchestration & Group Governance)

该层负责监控多代理协同工作时的风险涌现与协同计算效应。

- P-09 执行治理节点：在运行时动态注入治理策略，监督执行过程。
- P-02 AI 代理群体治理：监控多代理交互中的“协同计算效应”与宏观风险。
- P-17 行为熵异常检测：通过图结构熵变识别未知的涌现风险，防范“黑天鹅”事件。

5. L4 层：AI 执行层 (AI Execution / M-Core)

该层提供 AI 代理的物理隔离执行环境。

- P-07 执行成本结构：引入“数字摩擦”与算力税，使成本与风险等级挂钩以防止滥用。
- P-10 分级认知沙盒：通过三层隔离模型（物理、定向暴露、模拟）防御逆向渗透。
- P-21 JAC 边界生成协议：在协作中动态界定主权交集与授权边界。
- P-22 ISCP 跨主权协议：标准化不同系统间的意图对等交换与责任路由。

6. L5 层：系统抽象层 (System Abstraction)

该层负责连接数字世界与现实执行系统，进行接口标准化管理。

- P-06 多源治理：要求关键任务由多异构 AI 或数据源进行交叉验证，提高鲁棒性。

7. L6 层：物理锚定与价值确权层（Physical Anchoring & Value Confirmation）

该层作为不可篡改的物理可信根，并完成价值的最终闭环。

- P-20 主权收益确认协议：将确认行为与价值链绑定，确保人类主体获得扣除成本后的全部“主权溢价”。
- 三方见证确认协议（注：此协议常作为 P-13 的物理层增强）：针对高风险操作要求 Self OS 签名、信任联系人确认与硬件密钥三重校验。

总结：这 23 个协议通过分层咬合，实现了“不可绕过、不可代理、不可篡改”的主权通道，确保了“人类是唯一责任主体”这一核心公理的工程化落地。

附录 C：核心协议概览（维度说明）

AI-Native OS 由 23 个核心协议构成纵深防御体系，按人类主权守护维度分类：

一、本体维度：确立 AI 的边界与伦理基础

定义 AI 的本质属性及其在文明框架中的定位。

编号	协议名称	核心目的
P-01	本体论解耦	治理逻辑从“本体判定”转向“行为约束”
P-11	伦理保留条款	双向对称伦理审查机制
P-14	知识边界声明	明确声明 AI 能力边界

点击图片可查看完整电子表格


二、交互维度：规范人机协作流程

确保人类意图的纯净度与决策的可解释性。

编号	协议名称	核心目的
P-03	意图净化机制	过滤诱导性提问与外部意图污染
P-04	推理透明化	要求 AI 暴露推理过程，生成可审计证据
P-09	执行治理节点	运行时动态注入治理策略
P-05	信息真实性过滤	拦截低质/虚假信息输入
P-08	社会压力免疫	阻断算法诱导与情感操纵
P-13	生物确认不可代理	确保关键操作由人类亲自完成

点击图片可查看完整电子表格

三、安全维度：构建个体主权防护体系（SHC 防御簇）



通过主权健康检查（SHC）机制，在物理与内核层级防止主权流失。

编号	协议名称	核心目的
P-06	多源治理	关键任务需多异构 AI 交叉验证
P-07	执行成本结构	引入“数字摩擦”防止滥用
P-09	执行治理节点	运行时动态注入治理策略
P-10	分级认知沙盒	构建三层隔离防御逆向渗透
P-12	高风险行为评估	评估具身控制/状态延续等风险
P-15	认知健康度协议	[SHC 核心参数] 防范人类因疲劳导致的授权风险
P-16	授权累积熔断	防止主权在时间累积中静默流失
P-18	授权链条断裂	护人类在脆弱状态下的主权，防范非理性主权弃权行为
P-19	不可撤销授权熔断	[INAC-Fuse] 拦截非理性主权让渡，内核最后防线

四、协作治理维度：支撑多主体协同治理

由原“社会维度”演进而来，确立跨主权协作的法理与审计基石。

编号	协议名称	核心目的
P-02	AI 代理群体治理	监控多代理协同中的风险涌现
P-17	行为熵异常检测	监控行为模式异常波动
P-21	JAC 边界生成协议	动态界定协作中的主权交集范围（新增协作基础）
P-22	ISCP 跨主权协议	标准化不同 OS 间的意图对等交换（新增协作基础）
P-23	P-CC-Plus 四层审计	穿透 Org OS 算法黑盒，实现规则透明化（新增治理防御）

点击图片可查看完整电子表格

五、经济维度：确立价值与责任的绑定结构

经济维度不属于风险防御，而属于价值闭环

编号	协议名称	核心目的
P-20	主权收益确认协议	将确认行为与收益确权绑定，防止自动资产化与主权收益分离

点击图片可查看完整电子表格

注:本表仅展示协议核心目的。详细设计、触发机制与技术实现请参阅《AI-Native OS 技术白皮书》（开发中）。